

생성형 AI 활용 개발 실무

Lecture 03 이미지/동영상/음성 생성형 AI

동양미래대학교 컴퓨터소프트웨어공학과 황선희



동양미래대학교
DONGYANG MIRAE UNIVERSITY

실습 3 사전환경 구성

- 다음 pip 명령어로 diffusers 설치
 - `pip install git+https://github.com/huggingface/diffusers`
- `run.py` 코드를 실행하기 (모델 크기로 인해 다운로드 시간이 필요하므로, 미리 실행)
- 약 10GB의 HDD 여유 공간이 필요하므로, 노트북으로 작동에 어려움이 있을 수 있음
- 실행이 잘 되지 않거나, 설치에 어려움이 있는 경우 손을 들어주세요.

학습 목표

- 컴퓨터 비전 기술의 주요 모델에 대해 학습한다.
- 인공지능 기반 이미지 분류 기술과 생성기술의 작동과정에 대해 이해한다.
- 이미지 생성형 AI 기술을 활용한 서비스를 기획하고 구현한다.

목차

1. 컴퓨터 비전 기술의 발전과정
2. 비전/음성 생성형 AI 기술의 발전과정

목차

1. 컴퓨터 비전 기술의 발전과정
2. 비전/음성 생성형 AI 기술의 발전과정


이미지 분류를 위한 기술 발전 현황

- CNN(Convolutional Neural Networks) 모델은, ImageNet Dataset에 대한 성능 향상을 시작으로 초거대 모델까지 성장함
 - 이미지 처리를 위한 AI 모델 개발 시, 주로 ImageNet Dataset으로 학습된 모델을 활용하여 전이학습을 진행
- 대표 딥러닝 기반 이미지 분류 모델 (pytorch에 내장 or 오픈소스로 공개됨)
 - VGGNet(2014): 옥스퍼드 대학에서 발표한, 네트워크의 깊이를 19층까지 키워 성능을 향상시킨 모델
 - Inception(2014, GoogLeNet): 구글에서 발표한, 다양한 크기의 특징을 동시에 추출하는 모델
 - ResNet(2015): 마이크로소프트가 발표한, 모델의 깊이를 늘려도 안정적으로 작동하는 기술
 - DenseNet(2017): 특징 재사용이 극대화되며 파라미터 수를 줄인 모델
 - MobileNet(2017): 구글에서 개발한, 경량화 된 구조로 모바일/임베디드 시스템에 적합하게 개발된 모델
 - EfficientNet(2019): 구글에서 개발한, 작은 모델에서 효과적인 성능을 내도록 개발된 모델
 - ViT(2020): 구글에서 개발한, 트랜스포머 구조 기반의 이미지 처리를 위한 모델 (CNN 아님)
 - ConvNext(2022): 메타와 버클리에서 발표한, 최신 기술들을 활용한 초거대 CNN모델

대표적인 CNN 모델


• VGGNet(2014)

- Convolutional Layer와 Pooling Layer를 조합하여 깊은 모델을 구성 (깊이를 11, 13, 16, 19층으로 변경해 가며 비교실험)
- 깊이가 깊어질 수록 더 좋은 성능이 나오는 것을 확인



VGG16 Architecture

VGGNet




ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224×224 RGB image)					
conv3-64	conv3-64 LRN	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64
maxpool					
conv3-128	conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128
maxpool					
conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256 conv1-256	conv3-256 conv3-256 conv3-256	conv3-256 conv3-256 conv3-256 conv3-256
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					

대표적인 CNN 모델

- Inception(2014, GoogLeNet)

- 모델의 깊이를 깊게 늘리는 시도가 다양하게 이루어졌으나, 학습의 어려움이 존재했음 (학습데이터만 잘 맞추는 Overfitting 문제와 Computation 양의 증가)
- 이를 해결하기 위해, 연산량을 감소하기 위한 차원 축소기술(1x1 conv의 사용)을 제안하여 딥러닝 모델의 한계점 개선 (총 27층까지 늘림)




(b) Inception module with dimensionality reduction

대표적인 CNN 모델


• ResNet(2015)

- CNN모델의 깊이가 너무 깊은 경우에도 성능 저하 문제가 있음. 최적화(Optimization)가 잘 되지 않아서 발생한 것으로 판단하고, 이를 해결하기 위한 방법을 제안
- 이전 레이어의 정보가 손실되는 문제를 해결하기 위해, Skip Connection을 추가하여 기존 딥러닝 모델의 문제점을 개선하고 최대 **152층**까지 늘림

기존방식



ResNet



$H(x) - x = 0$ 이 되도록 학습

대표적인 CNN 모델

• DenseNet(2017)

- 모든 층을 서로 연결하여, 다음과 같은 장점을 가지는 모델을 제안
- 기울기 소실문제(모델의 앞부분 학습 어려움) 완화, 견고한 특징생성, 가중치(파라미터 수) 감소
- 264층까지 늘려가며 실험





Figure 1: A 5-layer dense block with a growth rate of $k = 4$. Each layer takes all preceding feature-maps as input.

대표적인 CNN 모델

• MobileNet(2017)

- 모바일 기기 등 컴퓨팅 파워가 부족한 기기에서 이미지 분류를 수행할 수 있도록 개발된 모델
- Depth-wise Separable Convolution을 사용하여 성능은 크게 감소시키지 않으며 파라미터 수를 감소시키는 기술 제안 (28층으로 구성)



대표적인 CNN 모델

• EfficientNet(2019)

- 사용하는 자원이 제한된 상태에서 네트워크의 깊이를 늘리고, 필터 수와 width를 증가시키고, 입력 이미지의 해상도를 높이기 위한 네트워크 구조를 제안
- 9층 구조인 B0로 ResNet-50과 DenseNet-169의 성능을 뛰어넘음




Figure 2. **Model Scaling.** (a) is a baseline network example; (b)-(d) are conventional scaling that only increases one dimension of network width, depth, or resolution. (e) is our proposed compound scaling method that uniformly scales all three dimensions with a fixed ratio.


Table 1. **EfficientNet-B0 baseline network** – Each row describes a stage i with $\hat{L}_i$ layers, with input resolution $\langle \hat{H}_i, \hat{W}_i \rangle$ and output channels $\hat{C}_i$. Notations are adopted from equation 2.

Stage i	Operator $\hat{\mathcal{F}}_i$	Resolution $\hat{H}_i \times \hat{W}_i$	#Channels $\hat{C}_i$	#Layers $\hat{L}_i$
1	Conv3x3	224×224	32	1
2	MBConv1, k3x3	112×112	16	1
3	MBConv6, k3x3	112×112	24	2
4	MBConv6, k5x5	56×56	40	2
5	MBConv6, k3x3	28×28	80	3
6	MBConv6, k5x5	14×14	112	3
7	MBConv6, k5x5	14×14	192	4
8	MBConv6, k3x3	7×7	320	1
9	Conv1x1 & Pooling & FC	7×7	1280	1

대표적인 CNN 모델

- ViT(Vision Transformer)(2020)


- CNN은 계층적이고 로컬한 특징을 추출하는 반면, ViT는 **이미지를 작은 패치로 나누고** 이들을 모델에 전달하여 **한번에 결과 출력**하는 형태 (글로벌한 정보를 한번에 처리함)



대표적인 CNN 모델

• ConvNext(2022)

- 최근 컴퓨터비전 CNN 모델들은, ViT(비전 트랜스포머) 모델에 밀려나고 있는 상황 (성능, 효율성 문제)
- CNN은 여전히 ResNet 등 오래된 기술들을 주로 활용한다는 점을 언급하며, 최신 기술들을 접목한 CNN 제안
- 반복학습 수, 연산량 축소 스킴, 커널사이즈 변경 등 다양한 실험을 통해 ViT를 뛰어넘는 CNN 모델을 제안



딥러닝 기반의 이미지 데이터 처리 (Pytorch)


- 1차원 데이터 처리 - Linear Layer

- Pytorch 코드: `torch.nn.Linear(입력 차원 수, 출력 차원 수)`
- 설계된 레이어만으로, 입출력 데이터의 전체 차원(dimension)을 알 수 있음



- 2차원 데이터(이미지) 처리 - Convolutional Layer



- Pytorch 코드: `torch.nn.Conv2d(입력 채널 수, 출력 채널 수, 필터 크기)`
- 설계된 레이어만으로, 입출력 데이터의 전체 차원(dimension)을 알 수 없음 (채널 수만 확인)



컨볼루션(Convolution) 연산

- 컨볼루션 연산

- 입력 이미지와 작은 크기의 행렬(=필터, 커널)을 겹치며 곱셈 → 합산하는 연산




컨볼루션(Convolution) 연산

- 컨볼루션 연산에 사용되는 필터


- 입력 특징 맵이 $m \times n \times k$ 텐서라면, $h \times h \times k$ 필터(**w, 가중치**) 사용
- 필터 여러 개(k' 개)로 다양한 특징 맵을 추출하며, 필터 마다 하나의 바이어스 존재 (필터 당 $kh^2 + 1$ 개 w)

*텐서(Tensor)란? 데이터의 배열



(a) 세부 내용

그림 8-6 컨볼루션층



(b) 간결한 블록 표현


컨볼루션(Convolution) 연산

- 컨볼루션 레이어의 주요 요소


- 커널(Kernel): 컨볼루션 연산에 사용되는 작은 행렬 (**w**)
- 필터(Filter): 여러 커널을 포함하는 개념 (커널의 집합, **w**)
- 스트라이드(Stride): 커널이 입력 이미지를 이동할 때 한번에 얼마나 이동하는지를 나타내는 값 (건너뛰기)
- 패딩(Padding): 입력 이미지의 가장자리에 추가로 픽셀을 덧붙이는 작업으로, 몇 픽셀을 붙이는지 (외곽)

출력 데이터의
Shape


입력 데이터와
커널(3x3)




Stride (1)
Padding (0)



Stride (1)
Padding (1)



Stride (2)
Padding (0)





Stride (2)
Padding (1)

Kernel Size가 3인 경우, Stride와 Padding에 따른 Output Shape


컨볼루션(Convolution) 연산

• 컨볼루션층의 연산 예시

- $5 \times 5 \times 3$ 특징 맵에 $3 \times 3 \times 3$ 필터를 2개 적용하고, Padding=1(zero-padding), Stride = 2인 경우 출력 특징 맵의 shape은? $5 \times 5 \times 3$ 특징 맵이 → ? 특징 맵이 됨




*높이 계산과정 동일



(b) 컨볼루션 연산

그림 8-7 컨볼루션층의 연산 사례



$$0 \times 1 + 0 \times (-1) + 0 \times 0 + 0 \times 1 + 2 \times (-1) + 2 \times 0 + 0 \times (-1) + 0 \times 1 + 0 \times 0 +$$

채널 0

$$0 \times 0 + 0 \times 0 + 0 \times 0 + 0 \times (-1) + 1 \times 1 + 0 \times 1 + 0 \times 1 + 1 \times 0 + 2 \times (-1) +$$

채널 1

$$0 \times (-1) + 0 \times 1 + 0 \times (-1) + 0 \times 1 + 0 \times 1 + 0 \times 1 + 0 \times 1 + 2 \times 0 + 2 \times (-1) + \underbrace{1}_{\text{바이어스}} = -4$$

채널 2

바이어스

입력 특징 맵

$x(5 \times 5 \times 3)$ 에 0패딩)

$x[:, :, 0]$

0	0	0	0	0	0	0
0	2	2	1	2	1	0
0	0	0	1	1	2	0
0	2	2	2	0	2	0

필터1

$u1(3 \times 3 \times 3)$

$u1[:, :, 0]$

1	-1	0
1	-1	0
-1	1	0

필터2

$u2(3 \times 3 \times 3)$

$u2[:, :, 0]$

0	1	1
0	-1	-1
1	1	0

로짓

$s(3 \times 3 \times 2)$

$s[:, :, 0]$

-4	11	9
1	2	3
1	3	6

ReLU 적용

출력 특징 맵

$x'(3 \times 3 \times 2)$

0	11	9
1	2	3
1	3	6

CNN 기반의 인공지능 모델 학습

- 역전파(Backpropagation) 알고리즘 사용(다층 퍼셉트론 MLP 학습 과정과 동일)
 - 컨볼루션 층과 완전 연결층(Fully Connected Layer)의 가중치(w , Parameters)를 학습
 - 풀링 층(Pooling Layer)는 가중치 없음 (데이터의 크기만 변경됨)




그림 8-13 컨볼루션 신경망을 학습하기 위한 역전파 알고리즘

C: 컨볼루션 층
P: 풀링 층 (크기 축소용)
FC: 완전 연결층

CNN 기반의 인공지능 모델 학습시 활용되는 손실함수

- 평균제곱오차 MSE(Mean Squared Error)

- 신경망 초기에 주로 활용되는 단순한 차 제곱 누적합

$$J(\mathbf{W}) = \frac{1}{|M|} \sum_{\mathbf{x} \in M} \|\mathbf{y} - \mathbf{o}\|_2^2 \quad (7.23)$$

- 교차 엔트로피 CE(Cross Entropy)

- 이진 분류의 경우, BCE(Binary Cross Entropy)를 사용 (y : 실제 정답 0 또는 1, p : 예측된 확률)

$$e = -y \log(p) + (1 - y) \log(1 - p)$$

모델이 클래스에 속할 확률

모델이 클래스에 속하지 않을 확률

- 다중 분류의 경우, 교차 엔트로피를 사용

- 두 확률분포의 차이를 구하기 위해 사용 (실제 데이터의 확률 분포와, 학습된 모델이 계산한 확률 분포의 차이)

$$\text{교차 엔트로피: } e = - \sum_{i=1, c} \overset{\text{실제 분포}}{y_i} \log(\underset{\text{예측을 통해 구한 분포}}{o_i}) \quad (8.1)$$

CNN 기반의 인공지능 모델 학습시 활용되는 손실함수

- Entropy(정보량)와 Cross Entropy(CE)
 - Entropy의 정의: 확률분포 $P(x)$ 에 대한 불확실성의 척도

$$H(P) = - \sum_x P(x) \log(P(x))$$

- 딥러닝 모델 학습에 사용되는 Cross Entropy의 정의: 실제 정답분포와 모델이 예측한 답의 분포간 차이

$$H(P, Q) = - \sum_x P(x) \log(Q(x))$$

- 실제 분포인 $P(x)$ 를 모르고, 모델링을 통해 예측
- 예측을 통해 구한 분포 $Q(x)$


*더 자세한 내용이 궁금하다면 KL-Divergence에 대해 학습하기

CNN 기반의 인공지능 모델 학습시 활용되는 손실함수


- Entropy와 Cross Entropy의 의미

$$H(P) = - \sum_x P(x) \log(P(x))$$

정보량 낮음 = 특별하지 않음
= 엔트로피 낮음 = 구분이 쉬움




정보량 높음 = 특별한 상황이 많음
= 엔트로피 높음 = 구분이 어려움



CE 낮음 = 두 분포의 차이가 적음
= 모델이 실제 답을 잘 예측함

CE 높음 = 두 분포의 차이가 큼
= 모델이 실제 답을 예측하기 어려움

$$H(P, Q) = - \sum_x P(x) \log(Q(x))$$




CNN 기반의 인공지능 모델 학습시 활용되는 손실함수

평균제곱오차


$$\left\{ \begin{array}{l} \text{상황 ①: } \text{MSE} = (0.0 - 0.1)^2 + (1.0 - 0.6)^2 + (0.0 - 0.2)^2 + (0.0 - 0.0)^2 + (0.0 - 0.1)^2 = 0.22 \\ \text{상황 ②: } \text{MSE} = (0.0 - 0.1)^2 + (1.0 - 0.2)^2 + (0.0 - 0.6)^2 + (0.0 - 0.0)^2 + (0.0 - 0.1)^2 = 1.02 \end{array} \right.$$

교차 엔트로피

$$\left\{ \begin{array}{l} \text{상황 ①: } \text{CE} = -(0.0 \log(0.1) + 1.0 \log(0.6) + 0.0 \log(0.2) + 0.0 \log(0.0) + 0.0 \log(0.1)) = 0.5108 \\ \text{상황 ②: } \text{CE} = -(0.0 \log(0.1) + 1.0 \log(0.2) + 0.0 \log(0.6) + 0.0 \log(0.0) + 0.0 \log(0.1)) = 1.609 \end{array} \right.$$




(a) 예측이 참값에 근접한 상황(①)



(b) 예측이 참값에서 벗어난 상황(②)

비전 트랜스포머(ViT) 기반 이미지 분류기술

- Image Patching (입력데이터 변환)
 - 이미지를 패치로 변환 ($224 \times 224 \rightarrow 16 \times 16$)
- Embedding Module
 - 패치를 네트워크에 전달가능 형태로 변환
- Transformer Encoder
 - 여러 개의 Self-attention으로 구성된, 관계학습 모듈
- Self-Attention Module
 - 이미지 내에서 중요한 부분을 식별 및 영역 간 관계를 학습하기 위한 모듈
- Classification Head
 - 분류를 위한 모듈 (MLP)



*Transformer는 언어모델(NLP) 분야에서 우수한 성과를 보여준 모델 구조 중 하나로, attention 모듈로 구성된 아키텍처

비전 트랜스포머(ViT) 기반 이미지 분류기술

- Image Patching (입력데이터 변환)

- 이미지를 패치로 변환 ($224 \times 224 \rightarrow 16 \times 16$)

- Embedding Module

- 패치를 네트워크에 전달가능 형태로 변환

- Transformer Encoder


- 여러 개의 Self-attention으로 구성된, 관계학습 모듈

- Self-Attention Module

- 이미지 내에서 중요한 부분을 식별 및 영역 간 관계를 학습하기 위한 모듈

- Classification Head


- 분류를 위한 모듈 (MLP)



*Transformer는 언어모델(NLP) 분야에서 우수한 성과를 보여준 모델 구조 중 하나로, attention 모듈로 구성된 아키텍처

비전 트랜스포머(ViT) 기반 이미지 분류기술


- Image Patching (입력데이터 변환)
 - 이미지를 패치로 변환 ($224 \times 224 \rightarrow 16 \times 16$)
- Embedding Module
 - 패치를 네트워크에 전달가능 형태로 변환
- Transformer Encoder
 - 여러 개의 Self-attention으로 구성된, 관계학습 모듈
- Self-Attention Module
 - 이미지 내에서 중요한 부분을 식별 및 영역 간 관계를 학습하기 위한 모듈
- Classification Head
 - 분류를 위한 모듈 (MLP)



*Transformer는 언어모델(NLP) 분야에서 우수한 성과를 보여준 모델 구조 중 하나로, attention 모듈로 구성된 아키텍처

비전 트랜스포머(ViT) 기반 이미지 분류기술

- Image Patching (입력데이터 변환)
 - 이미지를 패치로 변환 ($224 \times 224 \rightarrow 16 \times 16$)
- Embedding Module
 - 패치를 네트워크에 전달가능 형태로 변환
- Transformer Encoder
 - 여러 개의 Self-attention으로 구성된, 관계학습 모듈
- Self-Attention Module
 - 이미지 내에서 중요한 부분을 식별 및 영역 간 관계를 학습하기 위한 모듈
- Classification Head
 - 분류를 위한 모듈 (MLP)




비전 트랜스포머(ViT) 기반 이미지 분류기술

- Self-Attention의 중요성
 - Self-Attention은 입력 데이터 내의 서로 다른 부분 간의 관계를 모델링
 - 각 데이터 요소가 다른 모든 요소와의 관계를 계산, 이를 바탕으로 데이터의 중요한 부분에 더 많은 '주의'를 기울이는 방식 (예: 고양이 이미지에서 '얼굴'과 '꼬리'가 멀리 떨어져 있어도 동시에 중요한 특징으로 연결)
- Self-Attention 모듈은 쿼리, 키, 밸류 세가지 핵심 요소로 구성됨
 - 쿼리(Query, Q): 쿼리는 현재 처리 중인 특정 입력 요소(예: 이미지의 특정 패치)에 해당
 - 다른 모든 키와 비교하여 얼마나 관련이 있는지를 평가하는 역할
 - 키(Key, K): 키는 비교 대상이 되는 입력 요소
 - 각 키는 쿼리와 비교될 때 해당 입력 요소가 쿼리와 얼마나 관련이 있는지를 결정하는 데 사용
 - 밸류(Value, V): 밸류는 각 입력 요소가 가지고 있는 실제 정보
 - 쿼리는 모든 키와의 상호 작용을 통해 각각의 관련성 점수를 계산하고, 이를 밸류에 대한 가중치로 사용

비전 트랜스포머(ViT) 기반 이미지 분류기술

- Image Patching (입력데이터 변환)
 - 이미지를 패치로 변환 ($224 \times 224 \rightarrow 16 \times 16$)
- Embedding Module
 - 패치를 네트워크에 전달가능 형태로 변환
- Transformer Encoder
 - 여러 개의 Self-attention으로 구성된, 관계학습 모듈
- Self-Attention Module
 - 이미지 내에서 중요한 부분을 식별 및 영역 간 관계를 학습하기 위한 모듈
- Classification Head
 - 분류를 위한 모듈 (MLP)



*Transformer는 언어모델(NLP) 분야에서 우수한 성과를 보여준 모델 구조 중 하나로, attention 모듈로 구성된 아키텍처

[실습 1] 컨볼루션 연산 수행하기

- 입력 이미지에 컨볼루션 필터를 곱하는 경우 출력 값을 구하고, 한 픽셀에 대한 과정을 작성하시오.
 - 조건: Stride=1, Padding=0, Bias=0

1	2	0	1	3
4	1	0	2	1
3	2	1	0	2
0	1	3	2	1
2	0	1	3	2

입력 이미지

*

1	0	-1
1	0	-1
1	0	-1

필터

=

[실습 2] Pytorch 내장 모델을 활용하여 이미지 분류하기

- 사용자가 입력한 이미지(img.jpg) 분류기 만들기 (**Colab에서 실행할 것**)
 - 이미지 파일은 임의의 사진을 사용 (웹 검색 등 활용)
- Local PC에서 원활이 작동될 수 있는 가벼운 모델 선택하기
 - MobileNet, EffecienteNet, ResNet-18 등 자유롭게 선정
- 이미지 분류를 위한 클래스명(카테고리) 순서는 다음 링크의 정보를 활용
 - <https://raw.githubusercontent.com/anishathalye/imagenet-simple-labels/master/imagenet-simple-labels.json>
- 이미지 파일의 분류 결과를 다음과 같이 출력하도록 코드 작성하기



이미지 처리 중 ...

이미지 분류 결과: Egyptian Mau

목차

1. 컴퓨터 비전 기술의 발전과정

2. 비전/음성 생성형 AI 기술의 발전과정

비전/음성 생성형 인공지능 개요

- 기술 개요

- 텍스트, 이미지, 음성, 영상 등 다양한 데이터 형태를 새롭게 생성하는 인공지능 기술

- GAN(2014)


- 가짜를 만들고 진짜처럼 속이기 위해 경쟁하며 배우는 모델
- 딥페이크, 이미지합성, 스타일 변환, 해상도 복원 등에 활용

- Diffusion(2020)

- 노이즈를 거꾸로 지워가며 선명한 데이터를 복원·생성하는 모델
- 이미지 생성을 위한 DALL·E, Midjourney 등 모두 Diffusion 기반 모델
- SUNO AI 등 음성 생성에 활용되는 인공지능 모델은 주로 Diffusion+Transformer 기반

적대적 생성 신경망 GAN

- GAN(Generative Adversarial Network)는 이안 굿펠로우가 제안한, 적대적 학습 기반의 이미지 생성기술 (2014)
 - 적대적 학습이란? 다른 역할을 가진 두 모델 (D,G)가 서로 반대되는 개념으로 학습되도록 하는 학습기법




$$\min_G \max_D V(D, G)$$

$$V(D, G) = \mathbb{E}_{x \sim p_{data}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))]$$

x:real data, z:random variables, E: Expectation, 기대값, 확률변수의 평균값

적대적 생성 신경망 GAN

- GAN 학습과정 (Discriminator)




$$V(D, G) = \mathbb{E}_{x \sim p_{data}(x)} [\log \underline{D(x)}] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))]$$

D(x) 는 0, 1만 출력 → D(x)=1 인 경우 최대값 → D(x)가 1이 되려면 실제 데이터를 완벽하게 실제로 인식

적대적 생성 신경망 GAN

- GAN 학습과정 (Discriminator)




$$V(D, G) = \mathbb{E}_{x \sim p_{data}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - \underline{D(G(z))})]$$

1-D(G(z))도 1일 때 최대값 → 가짜데이터 z가 0으로 완벽하게 인식될 때 최대값이 됨

적대적 생성 신경망 GAN

- GAN 학습과정 (Generator)




$$\min_G \max_D V(D, \underline{G})$$

$$V(D, G) = \mathbb{E}_{x \sim p_{data}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - \underline{D(G(z))})]$$


1-D(G(z))가 0일 때 최소값 → D(G(z))=1 → 가짜데이터 z가 1로 인식될 때 해당 term이 최소값

GAN 기반의 이미지 생성형 AI

- GAN 기술이 생겨난 이후로 CGAN, ACGAN, WGAN 등 다양한 GAN의 변형 탄생
 - AC(Auxiliary Classifier) GAN, C(Conditional)GAN: 특정 클래스의 이미지를 생성하는 GAN
 - W(Wasserstein)GAN: GAN학습의 어려움(Gradient 소실, 이미지 품질저하, Mode Collapse 문제)을 해결
 - Pix2Pix, CycleGAN, StarGAN 등 Image-to-Image Translation 모델로도 확장





- 그러나, Diffusion기반의 Text-to-Image 모델이 인기를 끌며 GAN연구가 점점 사라짐



GAN 기반의 이미지 생성형 AI

- GigaGAN (2023): 포스텍, CMU, Adobe 공동연구로 공개된 GAN기반 기술
 - GigaGAN은 Diffusion 기반 방식에 비해, 절반 이하의 추론 속도로 속도 향상을 보여줌
 - 일반적으로 Diffusion 기반의 모델은 추론 단계에서도 많은 시간이 소요됨
 - GigaGAN은 GAN기술 확장 시 발생하던 문제를 해결하며 GAN기반 초거대 모델을 제안
 - 기존 GAN기반 기술은 모델의 크기를 키우는 데 기술적 한계점이 있었음




디퓨전 모델 (Diffusion Model)

- Diffusion은 데이터에 노이즈를 점진적으로 추가한 후, 역으로 제거하는 과정을 학습 → 랜덤 노이즈에서 점차 선명한 데이터를 생성하는 기술 (2020)


Forward (이미지 → 노이즈)

여러 단계를 통해 노이즈를 추가



Reverse (노이즈, 이미지)

Forward로 만든 x들을 통해 노이즈로부터 이미지 생성




- 이후, 클래스별 이미지를 생성하기 위해, Classifier를 추가하여 개선하기 위한 기술 등장
- 느린 속도를 해결하기 위한 Progressive Distillation 기법 등장
- 클래스 정보 없이 Guidance를 적용하기 위한 학습방법 등장

CLIP (Contrastive Language-Image Pretraining) (2021)


- OpenAI에서 개발한 언어-이미지 간 유사도 학습 모델
- 텍스트와 이미지를 같은 임베딩 공간에 매핑하여 서로간 유사도 측정이 가능하도록 학습

(1) Contrastive pre-training




CLAP (Contrastive Language-Audio Pretraining) (2023)

- LAION에서 개발한 언어-오디오 간 유사도 학습 모델
- 텍스트와 오디오를 같은 임베딩 공간에 매핑하여 서로간 유사도 측정이 가능하도록 학습



Stable Diffusion (2022)


- Stability AI에서 발표한 텍스트 기반 고화질 이미지생성모델 (오픈소스)
 - CLIP (Contrastive Language-Image Pretraining)을 활용하여 텍스트 → 벡터로 변환하여 입력으로 활용
 - WebUI형태의 오픈소스로 공개되어, 비전문가도 이미지 생성기술을 다방면으로 활용 중 (학습/추론)



*CLIP:텍스트와 이미지를 같은 임베딩 공간에 매핑하는 기술

Diffusion-Transformer(DiT) (2024)


- Stability AI에서 발표한 텍스트 기반 고품질 음성생성모델 (오픈소스)
 - CLAP(Contrastive Language-Audio Pretraining)을 활용하여 텍스트 → 벡터로 변환하여 입력으로 활용
 - Transformer의 Self-Attention을 도입하여 시간 축 전체에서 멀리 떨어진 부분을 연결할 수 있도록 모델 학습 (예: 도입부 리듬이 후반부에서도 반복되는 패턴 학습)



*CLAP:텍스트와 오디오를 같은 임베딩 공간에 매핑하는 기술

생성형 AI 기반 이미지 생성기술 평가

- <https://artificialanalysis.ai/text-to-image/arena>



생성형 AI 기반 비디오 생성기술 평가

- <https://artificialanalysis.ai/text-to-video/arena>

Artificial Analysis Models ▾ Speech, Image, Video ▾ Hardware Leaderboards ▾ AI Trends MicroEvals Arenas ▾ Articles About ▾

Help us understand how you use generative media - State of Generative Media 2025 Survey supported by fal - [Participate](#)


Image & Editing Video Text to Speech Music

[Video Arena](#) | [Text to Video Leaderboard](#) | [Image to Video Leaderboard](#) | [Personal Leaderboard](#)

Vote to reveal your model preference

[Submit a prompt](#)

Prompt: The giraffe turns and walks away from camera, knocking products off the shelves.



생성형 AI 기반 음악 생성기술 평가

- <https://artificialanalysis.ai/music/arena>

Follow us on Twitter or LinkedIn to stay up to date with future analysis [Twitter](#) [LinkedIn](#)

Artificial Analysis Models ▾ Speech, Image, Video ▾ Hardware Leaderboards ▾ AI Trends MicroEvals Arenas ▾ Articles About ▾ #K Insights Login

Help us understand how you use generative media - State of Generative Media 2025 Survey supported by [fal](#) - [Participate](#)

Image & Editing Video Text to Speech **Music**

[Music Arena](#) [Leaderboard](#) [Personal Leaderboard](#)

Vote to reveal your model preference [Submit a prompt](#)

 Listen to both music samples for at least 5 seconds each, then choose which one better matches the prompt:
Traditional gospel with church organ, walking bass lines, and handclaps

 0:00 Listen for 5 more seconds to vote

 0:00 Listen for 5 more seconds to vote

Keyboard Shortcuts

 Prefer left music	 Prefer right music	 Play / Pause
 Toggle player	 Restart	

생성형 AI 기반 Text-to-Image 리더보드

- <https://artificialanalysis.ai/text-to-image/arena/leaderboard-text>

Follow us on Twitter or LinkedIn to stay up to date with future analysis [Twitter](#) [LinkedIn](#)

Artificial Analysis Models Speech, Image, Video Hardware Leaderboards AI Trends MicroEvals Arenas Articles About

Search... Insights Login

Help us understand how you use generative media - State of Generative Media 2025 Survey supported by [fal](#) - [Participate](#)

Image & Editing Video Text to Speech Music

Image Arena **Text to Image Leaderboard** Image Editing Leaderboard Personal Leaderboard Explore NEW

Artificial Analysis Text to Image Leaderboard

Style

All General & Photorealistic Graphic Design & Digital Rendering Anime Cartoon & Illustration Vintage & Retro Traditional Art

Subject

All Text & Typography Commercial People: Portraits People: Groups & Activities Fantasy & Mythical Nature & Landscapes Futuristic & Sci-Fi UI/UX Design Physical Spaces

Added to the leaderboard in the last month
Seedream 3.0, Gemini 2.5 Flash, Seedream 4.0

Current models All models All Open weights More info [I→](#)

↑↓	Creator ↑↓	Model ↑↓	ELO ↑↓	95% CI	Appearances ↑↓	Release Date ↑↓
1	 ByteDance Seed	Seedream 4.0	1,228	-15/+15	3,115	Sept 2025
2	 Google	Imagen 4 Ultra Preview 0606	1,177	-11/+12	5,059	Jun 2025
3	 Google	Imagen 4 Preview 0606	1,172	-10/+11	5,128	Jun 2025

생성형 AI 기반 Image Editing 리더보드

- <https://artificialanalysis.ai/text-to-image/arena/leaderboard-image>

Artificial Analysis

Models ▾ Speech, Image, Video ▾ Hardware Leaderboards ▾ AI Trends MicroEvals Arenas ▾ Articles About ▾

Search... 🔍 Insights Login

Help us understand how you use generative media - State of Generative Media 2025 Survey supported by fal - [Participate](#)

Image & Editing Video Text to Speech Music

Image Arena Text to Image Leaderboard Image Editing Leaderboard Personal Leaderboard Explore NEW

Artificial Analysis Image Editing Leaderboard

Editing Action

All + Add Object or Element ✂ Remove Object or Element ✎ Modify Existing Object ✎ Edit Text or Document Content

👤 Edit People, Faces, or Character Attributes 📷 Change Camera View or Perspective 🎨 Alter Background, Texture, or Style

🔗 Multi-Step Instruction (Compound Edits)

Added to the leaderboard in the last month
SeedEdit 3.0, Qwen-Image-Edit, Gemini 2.5 Flash, Seedream 4.0

Current models All models All Open weights More info ↗

↕	Creator ↕	Model ↕	ELO ↕	95% CI	Appearances ↕	Release Date ↕
1	Google	Gemini 2.5 Flash	1,201	-13/+13	6,529	Aug 2025
2	ByteDance Seed	Seedream 4.0	1,199	-15/+16	3,272	Sept 2025
3	Black Forest Labs	FLUX.1 Kontext [pro]	1,091	-13/+11	6,487	May 2025
4	ByteDance Seed	SeedEdit 3.0	1,088	-15/+15	3,396	Jun 2025
5	Alibaba	Qwen-Image-Edit	1,088	-13/+12	6,824	Aug 2025


Google Gemini기반 이미지 편집 결과

- 기술 발전으로 인해 캐릭터 일관성 유지



알리바바의 Qwen기반 이미지 편집 결과

- 기술 발전으로 인해 캐릭터 일관성 유지



생성형 AI 기반 Text-to-Video 리더보드

- <https://artificialanalysis.ai/text-to-video/arena?tab=leaderboard-text>

Artificial Analysis Text to Video Leaderboard

Style: All, Abstract, Cartoon & Anime, Fantasy, Photorealistic, Sci-Fi, 3D Animation

Subject: All, Action, Animals, Buildings, Fashion, Show more (15)

Format: All, Long Prompt, Moving Camera, Multi Scene, Short Prompt

Added to the leaderboard in the last month: Seedance 1.0, Marey, PixVerse V5

Current models | All models | All | Open weights | More info

Rank	Creator	Model	ELO	95% CI	Appearances	Release Date
1	Google	Veo 3 (No Audio)	1,228	-9/+9	8,194	Jul 2025
2	MiniMax	Hailuo 02 Standard	1,209	-12/+11	5,162	Jun 2025
3	PixVerse	PixVerse V5	1,203	-11/+11	5,409	Aug 2025

생성형 AI 기반 Music Generation 리더보드

- <https://artificialanalysis.ai/music/arena?tab=leaderboard>

Artificial Analysis Music Arena Leaderboard

Image & Editing Video Text to Speech Music

Music Arena Leaderboard Personal Leaderboard

Artificial Analysis Music Arena Leaderboard

All Pop Rock Latin Global Niches Punk & Hardcore Funk & Disco Hip-Hop / Rap Jazz & Blues

House & Techno Metal & Hard Rock Reggae / Dancehall Electronic (EDM) R&B / Soul Classical / Orchestral

Alternative / Indie Other

Instrumental Vocals

↑↓	Creator ↑↓	Model ↑↓	ELO ↑↓	95% CI	Appearances ↑↓
1	🌟 Suno	Suno V4.5	1,107	-20/+22	1,977
2	II ElevenLabs	Eleven Music	1,057	-33/+36	999
3	🎵 Producer.ai	FUZZ-1.1 Pro	1,051	-20/+22	2,017
4	🎵 Producer.ai	FUZZ-2.0 Raw	1,025	-34/+38	1,041
5	🎵 Producer.ai	FUZZ-2.0	1,010	-32/+35	1,002

[실습 3] 이미지 생성형 AI 기술을 활용한 웹서비스 개발하기

- NVIDIA의 SANA 모델 기반 이미지 생성형 AI 기술을 활용한 인공지능 서비스 개발하기
 - 개발 필요성, 경제성, 서비스 적용 시 파급효과를 고려하여 주제를 선정
 - <https://nvlabs.github.io/Sana/>
 - https://huggingface.co/Efficient-Large-Model/Sana_600M_512px_diffusers
- Flask를 활용하여 웹 기반 서비스를 만들기
 - 서비스 예시: 로고 생성 자동화 서비스, 프롬프트 기반 웹툰/만화 생성, 아바타 제작 서비스, 밈 생성 서비스
- 모두 완성한 경우, 실습파일 제출 후 앞으로 나와주세요.