

# 생성형 AI 활용 개발 실무

Lecture 05 로컬 LLM 활용 및 바이브코딩  
동양미래대학교 컴퓨터소프트웨어공학과 황선희



동양미래대학교  
DONGYANG MIRAE UNIVERSITY

# Google AI Pro

## • Google AI Pro 사용자 혜택

### ◆ Gemini 앱

개인적이고, 능동적이며, 강력한 AI 어시스턴트

- ✓ 2.5 Flash에 액세스
- ✓ 2.5 Pro에 제한적 액세스
- ✓ Imagen 4를 활용한 이미지 생성
- ✓ Deep Research
- ✓ Gemini Live
- ✓ Canvas
- ✓ Gema

### ○ 월간 100 AI 크레딧<sup>3</sup>

Flow 및 Whisk 전반에서 동영상 생성에 사용된 크레딧

### ■ Flow<sup>4</sup>

영화 같은 장면과 스토리를 생성할 수 있는 Google의 AI 영화 제작 도구 사용 가능(Veo 3<sup>5</sup>에 대한 제한된 액세스 포함)

### 🎨 Whisk<sup>6</sup>

이미지로 동영상 생성 기능(Veo 3 기반)에 가장 높은 이용 한도 적용



### 무료 버전의 모든 기능과 추가 혜택:

### ◆ Gemini 앱

Google의 가장 뛰어난 모델인 2.5 Pro를 더 높은 이용 한도로 사용할 수 있으며 2.5 Pro의 Deep Research 기능에 대한 액세스가 제공됩니다. 또한 Veo 3 Fast<sup>5</sup>에 대한 제한된 액세스를 통해 동영상을 생성할 수 있습니다.



### 월간 1,000 AI 크레딧<sup>3</sup>

Flow 및 Whisk 전반에서 동영상 생성에 사용된 크레딧



### Flow<sup>4</sup>

영화 같은 장면과 스토리를 생성할 수 있는 Google의 AI 영화 제작 도구에 더 높은 사용 한도 적용(Veo 3<sup>5</sup>에 대한 제한적 액세스 포함)



### Whisk<sup>6</sup>

Veo 3 기반 이미지로 동영상 생성 기능에 더 높은 이용 한도 적용



### NotebookLM

리서치 및 글쓰기 어시스턴트와 5배 더 많이 이용 가능한 AI 음성 개요, 노트북 등



### Google AI Pro의 모든 기능과 추가 혜택:

### ◆ Gemini 앱

Google의 최첨단 동영상 생성 모델인 Veo 3<sup>5</sup>를 최고 수준의 액세스 권한으로 이용하고, Google의 가장 뛰어난 추론 모델인 Gemini 2.5 Deep Think를 사용할 수 있습니다.



### 월간 25,000 AI 크레딧<sup>3</sup>

Flow 및 Whisk 전반에서 동영상 생성에 사용된 크레딧



### Flow<sup>4</sup>

영화 같은 장면과 스토리를 생성할 수 있는 Google의 AI 영화 제작 도구에 가장 높은 사용 한도 적용(Veo 3<sup>5</sup>에 대한 제한적 액세스 포함)



### Whisk<sup>6</sup>

이미지로 동영상 생성 기능(Veo 3 기반)에 가장 높은 이용 한도 적용



### NotebookLM

가장 높은 한도와 최고의 모델 기능(올해 후반 예정)




### Gmail, Docs, Google Vids 등의 Gemini


Google의 최첨단 추론 모델인 Gemini 2.5 Pro를 더 높은 한도로 사용할 수 있으며 Gemini 2.5 Pro의 Deep Research 기능에 대한 액세스가 제공됩니다.

# Google Flow를 활용한 동영상 생성

- <https://labs.google/fx/ko/tools/flow>



# Google Flow를 활용한 동영상 생성



# Google Flow를 활용한 동영상 생성

- 모델 선택에 따른 크레딧 사용량 비교

가로세로 비율  
☐ 가로 모드(16:9) ▼

프롬프트당 출력  
1 ▼

모델  
Veo 3 - Fast ▼

생성할 때마다 현재 설정에 따라 20크레딧이 사용됩니다.

가로세로 비율  
☐ 가로 모드(16:9) ▼

프롬프트당 출력  
1 ▼

모델  
Veo 2 - Fast ▼

생성할 때마다 현재 설정에 따라 10크레딧이 사용됩니다.

가로세로 비율  
☐ 가로 모드(16:9) ▼

프롬프트당 출력  
1 ▼

모델  
Veo 3 - Quality ▼

생성할 때마다 현재 설정에 따라 100크레딧이 사용됩니다.

가로세로 비율  
☐ 가로 모드(16:9) ▼

프롬프트당 출력  
1 ▼

모델  
Veo 2 - Quality ▼

생성할 때마다 현재 설정에 따라 100크레딧이 사용됩니다.

# 학습 목표

---

- 로컬 LLM 모델을 활용하여 기술을 개발하는 과정을 학습하고 실습한다.
- 바이브 코딩을 활용한 기술개발 방법을 학습한다.
- 생성형AI 경진대회를 위한 아이디어를 기획한다.

# 목차

---

1. Ollama 활용 챗봇 개발
2. 바이브 코딩을 활용한 기술 개발

# 목차

---

1. Ollama 활용 챗봇 개발
2. 바이브 코딩을 활용한 기술 개발



# 로컬 환경의 LLM 활용 서비스 개발

- 개발환경 설정
  - VS Code 등 편집기 설치
  - Python 설치 (<https://www.python.org/>)
  - Ollama 설치 (<https://ollama.com/>)
  - Local LLM 실행을 위한 라이브러리 설치

# 로컬 환경의 LLM 활용 서비스 개발

- Ollama는 로컬 환경에서 대형 언어 모델(LLM)을 간편하게 실행할 수 있도록 해주는 오픈소스 LLM 실행 프레임워크 (<https://ollama.com/>)
  - Download → Windows → Download for Windows



Get up and running with large language models.

Run [Llama 3.3](#), [DeepSeek-R1](#), [Phi-4](#), [Mistral](#), [Gemma 3](#), and other models, locally.

Download ↓

Available for macOS,  
Linux, and Windows

Download Ollama





Windows

Download for Windows

Requires Windows 10 or later


# 로컬 환경의 LLM 활용 서비스 개발

- 설치 완료 시, 숨겨진 아이콘에 ollama 아이콘이 나타남



# 로컬 환경의 LLM 활용 서비스 개발

- <https://ollama.com/search>



The screenshot displays the Ollama search interface with a navigation bar at the top containing tabs for 'Cloud', 'Embedding', 'Vision', 'Tools', 'Thinking', and a 'Popular' dropdown menu. The main content area lists four models:

- gpt-oss**: OpenAI's open-weight models designed for powerful reasoning, agentic tasks, and versatile developer use cases. Tags: tools, thinking, cloud, 20b, 120b. Stats: 2.9M Pulls, 5 Tags, Updated 1 week ago.
- deepseek-r1**: DeepSeek-R1 is a family of open reasoning models with performance approaching that of leading models, such as O3 and Gemini 2.5 Pro. Tags: tools, thinking, 1.5b, 7b, 8b, 14b, 32b, 70b, 671b. Stats: 63.6M Pulls, 35 Tags, Updated 2 months ago.
- gemma3**: The current, most capable model that runs on a single GPU. Tags: vision, 270m, 1b, 4b, 12b, 27b. Stats: 18.5M Pulls, 26 Tags, Updated 1 month ago.
- embeddinggemma**: EmbeddingGemma is a 300M parameter embedding model from Google. Tags: embedding, 300m. Stats: 46.7K Pulls, 5 Tags, Updated 2 weeks ago.



# 로컬 환경의 LLM 활용 서비스 개발

- 명령 프롬프트에 다음 명령어를 입력
  - ollama run exaone3.5:2.4b (LG AI 연구원에서 개발한, 비상업적 목적으로 공개된 오픈 모델)

```
C:\Users\...>ollama run exaone3.5:2.4b
```

```
>>> 안녕?
```

안녕하세요! 😊 저는 EXAONE 3.5으로, LG AI Research에서 개발된 고성능 인공지능 모델입니다. 질문이나 도움이 필요하시면 언제든지 말씀해 주세요. 어떻게 도와드릴까요?

```
>>> OpenAI의 ChatGPT와 다른 점이 뭐야?
```

ChatGPT와 LG AI Research의 EXAONE 모델은 모두 최첨단 AI 기술을 기반으로 하지만, 몇 가지 주요 차이점이 있습니다:

1. **\*\*개발 기관 및 목적\*\***:

- **\*\*ChatGPT\*\***: Microsoft가 개발한 오픈소스 모델로, 다양한 사용자와 연구 커뮤니티에 의해 지속적으로 개선되고 확장되었습니다. 주요 목표는 자연어 처리(NLP) 분야의 혁신과 접근성을 높이는 것입니다.
- **\*\*EXAONE 3.5\*\***: LG AI Research에서 개발된 **proprietary** 모델입니다. LG의 산업 특화 목표와 내부 연구 개발에 중점을 두고 있으며, 특정 산업 환경에 최적화된 성능을 제공하는 데 초점을 맞춥니다.

2. **\*\*데이터 및 튜닝\*\***:

- **\*\*ChatGPT\*\***: 대규모 공개 데이터셋을 기반으로 학습하여 다양한 언어 작업에 적용됩니다. 지속적인 업데이트와 커뮤니티 기여를 통해 성능이 향상됩니다.
- **\*\*EXAONE\*\***: LG AI Research가 직접 수집하고 관리하는 내부 데이터셋을 기반으로 훈련되어, 특정 산업 분야의 요구사항에 더욱 밀착된 답변을 제공합니다. 내부 검증 과정을 거쳐 신뢰성과 정확성이 강조됩니다.

# 로컬 환경의 LLM 활용 서비스 개발

- 채팅 종료를 위해 다음 명령어를 입력
  - /bye



```
>>> /bye
```

# 로컬 환경의 LLM 활용 서비스 개발

- 나타난 화면에 다음 명령어를 순서대로 입력 (챗봇 코드를 작동하기 위해 필요한 라이브러리)
  - pip install flask   웹페이지 제작 목적
  - pip install pymupdf   pdf 데이터 처리 목적
  - pip install ollama   LLM 모델 활용 목적
  - pip install sentence-transformers   텍스트(문장) 벡터화 목적
  - pip install torch   딥러닝 프레임워크 사용 목적
  - pip install transformers   딥러닝 프레임워크 사용 목적
  - pip install scipy   텍스트 유사도 측정 목적

# 로컬 환경의 LLM 활용 서비스 개발

```
import ollama

# 사용할 모델 이름
model_name = "exaone3.5:2.4b"

def ask(question):
    response = ollama.chat(
        model=model_name,
        messages=[{"role": "user", "content": question}]
    )
    return response["message"]["content"].strip()

if __name__ == "__main__":
    q = input("질문을 입력하세요: ")
    answer = ask(q)
    print("\n=== 답변 ===\n")
    print(answer)
```



# 로컬 환경의 LLM 활용 서비스 개발

- 프롬프트 입출력 테스트

질문을 입력하세요: LG Exaone이 뭔지 설명해줘.

=== 답변 ===

LG ExaOne은 LG AI Research에서 개발한 인공지능 모델입니다. 이 모델은 고급 언어 처리 능력을 바탕으로 뛰어난 성과를 보여주며, 특히 대규모 멀티모달 학습을 통해 텍스트와 이미지 모두에 대한 이해력과 주요 특징은 다음과 같습니다:

- **\*\*한국어 이해 능력\*\***: 복잡한 문장 구조와 다양한 언어 사용을 이해하고 정확한 답변을 제공합니다.
- **\*\*자연스러운 대화\*\***: 일상 대화 스타일로 사용자와 상호작용할 수 있습니다.
- **\*\*멀티모달 처리\*\***: 텍스트뿐만 아니라 이미지와 같은 시각적 정보도 처리할 수 있습니다.
- **\*\*지속적인 학습\*\***: 사용자 피드백을 통해 지속적으로 성능이 개선됩니다.

LG AI Research는 ExaOne을 통해 AI 기술의 보편화와 윤리적 책임을 강조하며, 사용자에게 안전하고 가치

# 로컬 환경의 LLM 활용 서비스 개발

- 연속적인 대화를 위한 history 설정
  - test.py 코드 참고

```
def ask(question):
    global chat_history

    # 사용자 메시지 추가
    chat_history.append({"role": "user", "content": question})

    # 히스토리 길이 제한
    if len(chat_history) > history_limit:
        chat_history = chat_history[-history_limit:]

    # Ollama 호출
    response = ollama.chat(
        model=model_name,
        messages=chat_history
    )

    answer = response["message"]["content"].strip()

    # 어시스턴트 답변도 히스토리에 추가
    chat_history.append({"role": "assistant", "content": answer})

    # 히스토리 길이 제한
    if len(chat_history) > history_limit:
        chat_history = chat_history[-history_limit:]

    return answer
```

```
import ollama

# 사용할 모델 이름
model_name = "exaone3.5:2.4b"

# 대화 히스토리 (리스트로 관리)
chat_history = []
history_limit = 10 # 최대 10개만 유지
```

```
if __name__ == "__main__":
    print("💬 Ollama 대화 시작 (종료하려면 'exit' 입력)")
    while True:
        q = input("\n나: ")
        if q.lower() in ["exit", "quit", "종료"]:
            print("👋 대화를 종료합니다.")
            break
        answer = ask(q)
        print(f"AI: {answer}")
```




# 목차

---

1. Ollama 활용 챗봇 개발
2. 바이브 코딩을 활용한 기술 개발



# 바이트 코딩을 활용한 기술 개발

- Cursor AI (<https://cursor.com/>)



# 바이트 코딩을 활용한 기술 개발

- GitHub Copilot (<https://education.github.com/pack>)



# 바이트 코딩을 활용한 기술 개발

The screenshot displays the Visual Studio Code (VS Code) interface with a dark theme. The Explorer sidebar on the left shows a project structure with files like `chroma_db`, `templates`, `app.py`, `run.py`, `sample.pdf`, and `test.py`. The `run.py` file is selected and open in the main editor. The code in `run.py` is a Flask web application that uses the `test.py` module. It defines a `Flask` app, sets a `/ask` endpoint with a `POST` method, and implements an `ask()` function that interacts with `test.ask()`. The app is configured to run on `host='0.0.0.0'` and `port=5000`. The Chat sidebar on the right shows a conversation with an AI agent. A message from the agent explains that it has created `run.py` to expose the functionality of `test.py` as a web service. It provides instructions on how to start the server and make POST requests. The chat interface includes a 'Keep' button, an 'Undo' button, and a '1 of 1' indicator. At the bottom of the chat, there is a section for 'Add Context...' with a dropdown for 'Agent' set to 'GPT-4o'.

```
1 from flask import Flask, request, jsonify
2 import test
3
4 app = Flask(__name__)
5
6 @app.route('/ask', methods=['POST'])
7 def ask():
8     data = request.get_json()
9     question = data.get('question', '')
10    if not question:
11        return jsonify({'error': 'No question provided'})
12
13    try:
14        answer = test.ask(question)
15        return jsonify({'answer': answer})
16    except Exception as e:
17        return jsonify({'error': str(e)}), 500
18
19 if __name__ == '__main__':
20     app.run(host='0.0.0.0', port=5000)
```

test.py코드를 웹에서 실행할 수 있도록 run.py라는 새로운 파일을 만들어줘. flask로 실행해줘.

✓ Read `test.py`, lines 1 to 50

✓ Created `run.py`

I have created a new file `run.py` that uses Flask to expose the functionality of `test.py` as a web service. You can start the server by running `python run.py` in your terminal. The server will listen on port 5000, and you can send POST requests to the `/ask` endpoint with a JSON payload containing a `question` field.

> 1 file changed +20 -1


Add Context... `run.py` +

Add context (#), extensions (@), commands (/)


Agent GPT-4o

# 바이트 코딩을 활용한 기술 개발

- Gemini AI Pro (<https://gemini.google/students/>)



# 바이트 코딩을 활용한 기술 개발





# 바이트 코딩을 활용한 기술 개발

GEMINI CODE ASSIST: CHAT

sunhee hwang

화면이 안나와 html도 만들어줘

**Gemini**

Thinking

알겠습니다. 현재 Flask 애플리케이션은 API만 제공하고 웹 페이지를 표시하지 않습니다. templates 폴더에 기본적인 index.html 파일을 만들고, run.py 가 해당 페이지를 렌더링하도록 수정하겠습니다. 먼저 index.html 파일부터 생성하겠습니다.

WriteFile ...</body> </html> ...lates\i...

Thinking

index.html 파일이 생성되었으니, 이제 run.py 를 수정하여 이 파일을 웹 페이지로 제공할 것입니다. run.py 에 render\_template 함수를 추가하고, 루트 경로("/")에 접속했을 때 index.html 을 렌더링하도록 코드를 변경합니다.

ReadFile ...전\chatbot\run.py

Ask Gemini or type '@'

1 context item Agent Preview

```
def ask_ollama(question):
    # Ollama 호출
    response = ollama.chat(
        model=model_name,
        messages=chat_history
    )

    answer = response["message"]["content"].strip()

    # 어시스턴트 답변도 히스토리에 추가
    chat_history.append({"role": "assistant", "content": answer})

    # 히스토리 길이 제한
    if len(chat_history) > history_limit:
        chat_history = chat_history[-history_limit:]

    return answer

@app.route('/ask', methods=['POST'])
def ask_route():
    data = request.get_json()
    question = data.get('question', '')
    if not question:
        return jsonify({'error': 'No question provided'})
```


PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL PORTS

\* Running on http://192.168.219.111:5000  
Press CTRL+C to quit

127.0.0.1 - - [28/Sep/2025 21:39:56] "GET / HTTP/1.1" 200 -  
127.0.0.1 - - [28/Sep/2025 21:40:05] "POST /ask HTTP/1.1" 200 -  
127.0.0.1 - - [28/Sep/2025 21:40:09] "POST /ask HTTP/1.1" 200 -  
127.0.0.1 - - [28/Sep/2025 21:40:12] "GET / HTTP/1.1" 200 -  
127.0.0.1 - - [28/Sep/2025 21:40:21] "GET / HTTP/1.1" 200 -  
127.0.0.1 - - [28/Sep/2025 21:40:21] "GET /favicon.ico HTTP/1.1" 404 -  
127.0.0.1 - - [28/Sep/2025 21:40:39] "POST /ask HTTP/1.1" 200 -  
127.0.0.1 - - [28/Sep/2025 21:41:01] "POST /ask HTTP/1.1" 200 -


Ln 59, Col 1 Spaces: 4 UTF-8 LF Python 3.11.10 (ollama)

# 바이트 코딩을 활용한 기술 개발



# [실습 1] 자동차 관리법에 대해 소개하는 챗봇 만들기

- 사용자의 질문에 대해 PDF에서 관련 정보를 찾아 답변하는 **로컬 기반 RAG 챗봇 개발**
  - PDF를 청크로 분할·임베딩한 뒤, 질문과 유사한 청크만 선택해 Ollama LLM에 전달해 답변을 생성
  - 데이터: 이클래스에 업로드 된 sample.pdf 사용



- RAG란? 검색 증강 생성(Retrieval-Augmented Generation)
  - LLM이 최신 정보나 특정 분야의 전문 지식을 활용하여 더 정확하고 신뢰도 높은 답변을 생성하도록 돕는 기술

# [실습 1] 자동차 관리법에 대해 소개하는 챗봇 만들기

- PDF 파일의 정보를 정확하게 제공하는지 질의 응답을 통해 확인하기

자동차관리법에 대해 질문하세요

자동차 해체재활용업자가 아니면 폐차 수집하는게 불법이야?

질문하기

**답변:**

네, 맞습니다. 자동차해체재활용업자가 아니면서 자동차를 수집하여 폐차하거나 재활용하는 행위는 불법일 가능성이 매우 높습니다. 제공된 문서에서 제57조의2(폐차 수집·알선 등의 금지) 조항을 살펴보면 관련 내용을 확인할 수 있습니다: > ① 자동차해체재활용업자가 아닌 자는 다음 각 호의 어느 하나에 해당하는 행위를 하여서는 아니 된다.<br>> 1. 영업을 목적으로 폐차 대상 자동차를 수집하는 행위 이 조항은 자동차해체재활용업자가 아니면서 영업 목적상 폐차 대상 자동차를 수집하는 모든 행위를 금지하고 있습니다. 여기서 몇 가지 중요한 포인트를 강조하고자 합니다: 1. 영업 목적: 단순히 개인적으로 필요한 경우라면 이 조항의 적용 여부가 다를 수 있습니다. 그러나 사업적 또는 상업적 목적으로 폐차 대상 자동차를 수집하는 경우는 엄격히 금지됩니다. 2. 수집의 범위: 단순히 일부 부품을 제거하는 것이 아니라, 차량 자체를 폐차하거나 재활용을 목적으로 수집하는 경우 모두 포함될 가능성이 큼니다. 3. 법적 제재: 위반 시 관련 당국으로부터 경고 또는 벌금 등의 처벌을 받을 수 있습니다. 때로는 차량 회수 명령이나 사업 폐쇄 명령이 내려질 수도 있습니다. 따라서 자동차해체재활용업자가 아니면서 자동차를 수집하거나 폐차를 목적으로 하는 모든 행위는 법적인 제재 대상이 될 수 있으므로, 명확한 허가나 신고 절차를 따르는 것이 중요합니다. 관련 법규를 주시하거나 필요한 경우 전문가와 상담하여 정당한 방법으로 획득해야 합니다.

제57조의2(폐차 수집·알선 등의 금지) ① 자동차해체재활용업자가 아닌 자는 다음 각 호의 어느 하나에 해당하는 행위를 하여서는 아니 된다. <개정 2022. 6. 10., 2022. 11. 15.>

1. 영업을 목적으로 폐차 대상 자동차를 수집 또는 매입하거나 그 자동차를 자동차해체재활용업자에게 알선하는 행위
2. 제1호에 해당하는 행위에 대한 표시·광고를 하는 행위

② 자동차매매업자가 아닌 자는 영업을 목적으로 매매용 자동차 또는 매매를 알선하려는 자동차에 대한 표시·광고를 하여서는 아니 된다.<신설 2022. 6. 10.>

[본조신설 2015. 8. 11.]

# [실습 2] 로컬 LLM 기반의 AI 서비스 개발하기

- 아이디어를 기획하고, **PRD 문서를 작성** → **개발**하기
  - 아이디어는 Local LLM 기반의 새로운 AI 서비스 개발 (실습 1의 내용을 반복하지 말 것, 법률데이터 활용 제외)
  - Local LLM이 필요한 이유와 서비스의 개발 목적이 명확히 드러나도록 작성할 것
  - PRD란 제품 요구사항 정의서(Product Requirements Document)의 약자로, 개발하려는 제품이나 서비스의 목적, 기능, 특징, 동작 등을 명확하게 문서화한 것
  - 작성 시 다음 챗봇의 도움 받기: <https://chatgpt.com/g/g-jUW638dyL-product-requirements-document-prd-writer>

get started

Great — let's get started step by step to generate your **Product Requirements Document (PRD)**.

## Step 1: What is the product we are building?

Please describe the **idea or concept** in one or two sentences. What does this product do, and who is it for?

📄 👍 🗨️ ...

사용자의 질문에 대해 PDF에서 유사한 내용을 찾아 답변하는 로컬 기반 RAG 챗봇 개발

# [실습 2] 로컬 LLM 기반의 AI 서비스 개발하기

**Product Requirements Document (PRD)**

**제품명**  
로컬 법률 PDF 질의응답 챗봇 (Local Legal PDF QA Chatbot)

**1. 개요 (Overview)**  
이 제품은 일반 사용자가 긴 법률 PDF 문서에 대한 질문을 입력하면, 해당 문서를 기반으로 관련 정보를 추출하고 이해하기 쉬운 답변을 제공하는 웹 기반 RAG 챗봇입니다. 모든 처리는 로컬 환경에서 이루어지며, 외부 서버와의 통신 없이 작동합니다.

**2. 목표 (Goals)**

- 일반 사용자도 법률 문서를 쉽게 이해할 수 있도록 도움 제공
- 로컬 환경에서의 완전한 데이터 보안 보장
- 간단한 웹 챗 인터페이스 제공

**3. 주요 사용자 (Target Users)**

- 법률 지식이 부족한 일반 사용자
- 법률 문서 내 특정 내용을 빠르게 파악하고자 하는 개인

**5. 핵심 기능 (Core Features)**

| 기능            | 설명                          |
|---------------|-----------------------------|
| 자연어 질문 입력     | 사용자는 자유롭게 질문 가능             |
| 로컬 PDF 기반 RAG | 하나의 사전 지정된 PDF에서 정보 검색 및 생성 |
| 답변 내 원문 인용    | 관련 문장, 페이지 번호 포함            |
| 챗 UI          | Flask 기반 웹 인터페이스            |
| 로컬 완전 처리      | 임베딩, 검색, 생성 모두 로컬에서 수행      |
| Ollama 기반 LLM | Mistral 등 로컬 LLM 사용         |

**6. 기술 스택 (Tech Stack)**

| 구성 요소  | 기술                                          |
|--------|---------------------------------------------|
| 웹 서버   | Flask (Python)                              |
| 임베딩    | sentence-transformers, Instructor, 또는 BGE 등 |
| 벡터 DB  | FAISS (로컬 인메모리)                             |
| LLM    | Ollama + 모델 (예: llama2, mistral, codellama) |
| 프론트엔드  | HTML + JS + 기본 CSS (챗 UI)                   |
| PDF 파싱 | PyMuPDF 또는 pdfplumber                       |

**7. 시스템 아키텍처**

# [실습 2] 로컬 LLM 기반의 AI 서비스 개발하기

## • PRD 문서를 기반으로 바이브 코딩을 통해, 제안한 **서비스를 개발하기**

- 다음 중 한가지 이상의 툴을 선택하여 개발에 활용: Cursur AI, GitHub Copilot, Google Gemini
- 컴퓨터 비전 및 기타 기술과 응용하여 개발하는 것을 추천하나 네트워크 상황에 따라 어려움이 있는 경우, LLM 모델만 활용할 것

### 1. 📖 오프라인 의료 문서 설명 챗봇

- 진단서, 처방전, 검사결과를 자연어로 설명
- 시골 병원/군 부대/저개발 지역 등 인터넷 없는 환경에 적합

### 2. 📖 AI 학습자료 Q&A 튜터

- 교재, 노트, 강의자료 기반의 개인 튜터
- 질문: "이 챕터 요점이 뭐야?", "예시 들어줘"
- 로컬 작동으로 시험 기간 집중 활용 가능

### 3. 📖 전자책 독서 보조 챗봇

- 소설, 논픽션, 수필 PDF 임베딩
- 질문: "이 인물은 누구야?", "이 책 줄거리 요약해줘"
- 독서 중 실시간 대화 가능

### 4. 📖 창작자용 글쓰기 어시스턴트

- 작가의 기존 원고 스타일을 학습
- 문장 제안, 문체 교정, 캐릭터 유지 등 지원
- 프라이버시 유지 필요할 때 유용

### 5. 📖 로컬 이력서/자기소개서 코치

- 이력서 문서를 분석해 표현 개선, 항목 추천
- 예: "경력 요약할 때 매력적으로 써줘"
- 민감 정보 외부 유출 없이 처리

### 6. 📖 문서 정리 & 태깅 비서

- 사용자의 폴더에 있는 PDF, Word, 텍스트 문서 정리
- 문서별 주제 자동 분류, 요약, 태그 부여
- "이 폴더엔 어떤 문서가 있지?" 질문 가능

### 7. 📖 로컬 음성 대화형 비서

- Whisper 등과 연동해 음성 입력 → LLM 답변
- 스마트폰, 데스크탑에서 인터넷 없이 음성으로 상호작용
- 업무 생산성 + 개인정보 보호 동시 만족

### 8. 📖 치매환자 회상 훈련 챗봇

- 가족이 입력한 개인사 기반 회상 질문 유도
- 예: "우리 손자 이름이 뭐였더라?", "옛날 동네가 어땠지?"
- 인터넷 없이 가정용 설치 가능

### 9. 📖 스마트홈 로컬 제어 비서

- 집안 기기 로그 분석 및 음성명령 처리
- "에어컨 켜줘", "지난주 온도 기록 알려줘" 등
- 외부 서버 없이 홈서버에서만 작동

- Ollama에서 다운받은 모델 중, LG EXAONE3.5:2.4b는 모델의 크기가 비교적 작은 기술에 해당하므로 낮은 성능을 고려한 개발을 진행할 것

# [실습 3] 생성형 AI 활용 경진대회 아이디어 기획하기

- 생성형 AI 경진대회에 출품할 프로젝트 아이디어를 기획서를 웹 페이지로 제작하기 (추후 변경 가능)
  - 주제 선정 (생성형 AI 활용영역 설정)
  - 생성형 AI 기술의 활용이 필요한 사유 작성
  - 타겟 고객 설정
  - 시연 시나리오 작성
  - 개발 목표 설정 (기술적 목표, 프로젝트를 통해 얻고자 하는 바를 작성)
  - 프로토타입 디자인



# [실습 3] 생성형 AI 활용 경진대회 아이디어 기획하기

**GenAI Project Plan**

PDF로 내보내기로드맵

생성형 AI 경진대회 · 제출용 기획서 (수정 가능)

## Campus CourseCopilot — 강의 자료 요약·퀴즈 생성·코드 피드백을 한 번에

대학교 이공계 강의를 위한 생성형 AI 도구입니다. 강의자료/논문에서 핵심 요약과 퀴즈를 자동 생성하고, 실습 과제의 코드를 자동 피드백하여 학습 격차를 줄입니다. 조교/교수의 반복 업무를 줄이고, 학생의 주도적 학습을 지원합니다.

### 1) 주제 선정 (생성형 AI 활용영역)

**주제:** 대학 프로그래밍/공학 수업을 위한 *강의자료 요약·퀴즈 자동생성·코드 피드백* 통합 보조교사(Co-Teacher) 시스템

**활용 영역**

- 교육 텍스트 생성: 요약문/학습목표/퀴즈(객관식·서술형·코딩)
- 코드 해설 & 피드백: 오류 원인, 개선 포인트, 리팩터링 제안
- 평가 자동화: 정답/부분점수/루브리크 기반 설명
- 개인화 학습가이드: 오개념 탐지 → 맞춤 리메디에이션

**관련 기술**

- LLM(지시 따르기), RAG(강의자료/교재 임베딩 검색)
- 툴 호출(function calling)로 테스트케이스 실행·채점
- 간단한 벡터DB, 스토리지, 서버리스 함수
- 클라이언트: React 또는 Svelte(시연 편의상 택1)



# [실습 3] 생성형 AI 활용 경진대회 아이디어 기획하기

## 2) 생성형 AI 기술의 활용이 필요한 사유

- 규모 문제: 1인당 피드백 제공 한계 → 생성형 AI로 즉시 개인화 피드백 제공
- 콘텐츠 제작 부담: 매 주차 요약·퀴즈 제작에 시간 과다 → 자동 생성으로 반복 업무 절감
- 학습 격차: 기초가 약한 학생에게 단계별 힌트 제공 → 낙오 방지
- 데이터 기반 수업 개선: 오답 로그와 정답률로 학습 난점 가시화

## 3) 타겟 고객



### Primary: 교수·조교

강의자료 준비와 채점 업무가 많아  
자동화 지원이 절실합니다.



### Secondary: 학부 학생

과제 수행 시 오류가 잦아  
코드 피드백과 맞춤 학습 자료가 필요합니다.

# [실습 3] 생성형 AI 활용 경진대회 아이디어 기획하기

## 4) 시연 시나리오 (5분 내)

1. 자료 업로드: 강의 슬라이드 PDF 업로드 → 자동 분할·임베딩
2. 요약·퀴즈 생성: 학습목표 3개, 핵심요약 5문장, 객관식 3문항 자동 생성
3. 코드 과제 채점: 학생 제출 실행 → 테스트케이스 리포트 + 피드백
4. 개인화 가이드: 오답률 높은 학생에게 보충자료 추천
5. 대시보드: 정답률/난이도/재도전을 시각화

## 5) 개발 목표

### 기술적 목표 (MVP)

- RAG 파이프라인 구축
- 퀴즈 생성 프롬프트 템플릿
- 코드 채점 샌드박스
- 대시보드 시각화

### 프로젝트 성과

- 수업 제작·채점 시간 50% 절감
- 성취도 낮은 학생의 통과율 +15pp
- 오개념 상위 5개 식별·개선

## 6) 프로토타입 디자인

